

BANK MARKETING

Agustín Casal, Teo Martínez, Francisco Medrano y Martina Saldías

TRABAJO FINAL MACHINE LEARNING ICD 70AT 2026 | UNIVERSIDAD CATÓLICA ARGENTINA

// CAPÍTULO 01

¿De qué trata este proyecto?

Imagina que trabajas en el área de marketing de un banco. Tu equipo acaba de lanzar una campaña telefónica para ofrecerle a los clientes un depósito a plazo fijo — básicamente, una manera de ahorrar dinero con una tasa de interés garantizada. El problema es que llamar a todos los clientes es caro y lleva tiempo. ¿No sería genial poder saber de antemano quién va a decir que sí? Eso es exactamente lo que intenta hacer este proyecto. Usando datos reales de campañas anteriores de un banco portugués, entrenamos dos modelos de Machine Learning capaces de predecir si un cliente va a suscribir el depósito o no, antes de hacerle la llamada.

¿Qué es Machine Learning en palabras simples? Es enseñarle a una computadora a reconocer patrones en datos históricos para que pueda hacer predicciones sobre datos nuevos. Como cuando un médico aprende de miles de casos anteriores para diagnosticar mejor: el modelo "aprende" de campañas pasadas para predecir el resultado de las futuras.

El proceso que seguimos:

01 Carga y primera inspección: Leímos el archivo con 11.162 registros, revisamos cuántas columnas tiene y detectamos los primeros problemas (valores faltantes, tipos de datos).

02 Exploración de datos (EDA): Analizamos cada variable con gráficos: distribuciones, correlaciones, box plots y violin plots. Aquí descubrimos los patrones más interesantes.

03 Limpieza y preparación: Tratamos los valores nulos, convertimos texto en números y escalamos las variables para que los modelos funcionen correctamente.

04 Entrenamiento de modelos: Entrenamos dos algoritmos distintos: Regresión Logística y Random Forest, cada uno con sus fortalezas particulares.

05 Evaluación y comparación: Medimos qué tan bien predice cada modelo y los comparamos para determinar cuál es más útil para el banco

// CAPÍTULO 02

¿Con qué datos trabajamos?

El dataset contiene información sobre 11.162 clientes contactados por teléfono durante campañas de marketing del banco. Para cada cliente se registraron 16 características diferentes, desde su edad y ocupación hasta cuánto tiempo duró la conversación telefónica.

11.162 Clientes en el dataset

16 Variables por cliente



5289 Suscribieron (47,4%)

5.873 No suscribieron (52,6%)

¿Están equilibradas las clases?

Una pregunta clave antes de modelar: ¿hay muchos más "no" que "sí"? Si el 95% dijera no, el modelo podría volverse perezoso y predecir "no" siempre, acertando sin aprender nada útil. En nuestro caso, la distribución es bastante pareja: 52,6% no suscribió vs. 47,4% que sí lo hizo.

Variable objetivo: ¿Suscribió depósito?



¿Por qué importa el balance de clases? Si hubiera 9.000 "no" y solo 1.000 "sí", el modelo podría predecir "no" siempre y acertar el 90% de las veces sin aprender nada. Con clases equilibradas, el modelo está "obligado" a aprender las diferencias reales entre los dos grupos.

// CAPÍTULO 03


¿Qué encontramos en los datos?

Antes de entrenar cualquier modelo, exploramos el dataset en profundidad. Esta etapa se llama EDA (Análisis Exploratorio de Datos) y es donde descubrimos los patrones más interesantes. A continuación, los hallazgos más relevantes.

El hallazgo más fuerte: la duración de la llamada

La variable más predictiva de todas resultó ser la duración de la llamada telefónica. En promedio, los clientes que suscribieron hablaron 538 segundos (~9 minutos), mientras que los que no suscribieron hablaron apenas 224 segundos (~4 minutos). Es decir, el doble de tiempo. **Age, balance y campaign** muestran distribuciones mucho más similares entre grupos, lo que indica menor poder predictivo.

Box Plots: Variables numéricas vs. Suscripción




Box Plot: cada caja muestra dónde se concentra el 50% central de los valores. La línea del medio es la mediana. Las "bigotes" muestran los valores extremos. Se puede ver claramente que las llamadas de clientes que suscribieron son mucho más largas y dispersas.

¿Qué significa esto en la práctica? Una llamada larga indica que el cliente está interesado y haciendo preguntas. Una llamada corta es señal de que el cliente quiere colgar rápido. Aunque esta variable es muy predictiva, existe una trampa: solo la conocemos después de hacer la llamada. No podemos usarla para decidir a quién llamar. Es útil para entender el fenómeno, pero no para prevenir el costo de llamadas no fructíferas.

¿Importa la ocupación del cliente?

La ocupación del cliente tiene un impacto enorme. Los estudiantes y jubilados son, por lejos, los más propensos a suscribir. Los obreros y empleados de servicios son los menos interesados.




¿Por qué estudiantes y jubilados? Los jubilados tienen capital acumulado y menos gastos corrientes; un depósito a plazo fijo es atractivo para ellos. Los estudiantes, paradójicamente, pueden tener más ahorros familiares o mayor apertura a productos financieros nuevos. Los obreros, en cambio, suelen tener mayor necesidad de liquidez inmediata.


El efecto de la edad: Violin Plot

La edad también muestra un patrón interesante. Los clientes jóvenes (18-25) y los mayores de 65 años tienen tasas de suscripción muy altas, mientras que el grupo de mediana edad (36-55) es el más difícil de convencer.

Violin Plots: Densidad de variables según suscripción



Violin Plot simplificado: la altura de cada "violín" representa la tasa de suscripción de ese grupo etario. Se aprecia claramente la forma de "U": los extremos (jóvenes y mayores) tienen mayor tasa de conversión que el grupo de mediana edad.







El violín dividido muestra que en los tres estados civiles, los suscriptores (verde) tienden a ser levemente mayores que los no suscriptores (rojo). Los divorciados suscriptores tienen la mediana de edad más alta.

¡El historial previo importa muchísimo!

*Cada barra muestra qué porcentaje de clientes de esa categoría terminó suscribiendo. **Ocupación:** estudiantes **74,7%** y jubilados **66,3%** lideran ampliamente; los obreros están en el extremo opuesto (**36,4%**). **Estado civil:** los solteros suscriben más (**54%**) que los casados (**43%**). **Educación:** a mayor nivel educativo, mayor tasa.*

Una de las variables más poderosas es **poutcome**: el resultado de la campaña anterior con ese cliente. Si ya suscribió antes, las probabilidades de que lo haga de nuevo son altísimas.

Tasa de suscripción por variable categórica




Un cliente que ya suscribió en una campaña anterior tiene un 91,3% de probabilidad de volver a hacerlo. Este es un dato de oro para el equipo de marketing: los clientes fieles son los más valiosos.

Mapa de correlaciones

Para entender las relaciones entre todas las variables numéricas de forma simultánea, generamos un mapa de calor (heatmap). Cada celda muestra si dos variables se mueven juntas (correlación positiva, en rojo) o en sentido contrario (correlación negativa, en azul).

Mapa de Calor: Correlación entre variables numéricas



Cada celda muestra la correlación entre dos variables: **+1 = se mueven juntas**, **-1 = se mueven en sentido contrario**, **0 = sin relación**. El color rojo intenso indica correlación alta, el azul indica correlación negativa. **El dato clave: *duration* tiene correlación +0.45 con *deposit***, la más alta del dataset — confirma que la duración de la llamada es el predictor más fuerte. *campaign* correlaciona negativamente (**-0.13**): más contactos en la misma campaña se asocian con menos suscripciones, posiblemente por fatiga del cliente.

// CAPÍTULO 04

Los dos modelos entrenados

Entrenamos dos algoritmos distintos con los mismos datos y los evaluamos sobre el mismo conjunto de prueba (el 20% de los clientes que el modelo nunca vio durante el entrenamiento).

Modelo 1: Regresión Logística

A pesar del nombre intimidante, la Regresión Logística es un algoritmo sorprendentemente simple e interpretable. Imagínate que intenta dibujar una línea recta (en un espacio multidimensional) que separe a los


que suscribieron de los que no. Para cada cliente, calcula una probabilidad entre 0% y 100%: si supera el 50%, predice "sí suscribirá".

Su gran ventaja es que podemos ver exactamente **cuánto pesa cada variable** en la decisión. Si la duración de la llamada tiene un coeficiente de +0.8, sabemos que cada segundo adicional aumenta la probabilidad de suscripción.

Analogía simple: La Regresión Logística es como un formulario de solicitud de crédito: le asigna puntos a cada característica del cliente (edad, saldo, historial) y si la suma supera un umbral, aprueba el crédito (predice suscripción).

Matriz de Confusión — Regresión Logística

La Matriz de Confusión es la forma más honesta de entender los errores de un modelo. Divide las predicciones en 4 tipos según si acertó o se equivocó, y en qué sentido se equivocó.



~952 TN (Verdadero Negativo): Predijo “no” y el cliente realmente no suscribió. ✓ Acierto.


~855 TP (Verdadero Positivo): Predijo “Si” y el cliente realmente suscribió. ✓ Acierto.

~223 FP (Falso Positivo): Predijo “sí” pero no suscribió. El banco llama a alguien que igual diría no. *x*

~203 FN (Falso Negativo): Predijo “no” pero sí hubiera suscrito. Se pierde un cliente potencial. *x*

La Regresión Logística acierta en la mayoría de los casos (~80,9%). Los errores más comunes son los Falsos Positivos (el modelo es demasiado optimista) y los Falsos Negativos (pierde algunos clientes reales).

Curva ROC - Regresión Logística



La curva muestra el equilibrio entre detectar correctamente a los suscriptores (eje Y) y generar falsos positivos (eje X). **Cuanto más alejada de la diagonal punteada y más área encierre, mejor el modelo.** La línea diagonal representa un clasificador completamente aleatorio (AUC = 0,5). La Regresión Logística alcanza un **AUC = 0,861**, lo que significa que si le mostramos un cliente que suscribió y uno que no, el modelo identifica correctamente al suscriptor el **86,1% de las veces**.


Modelo 2: Random Forest

El Random Forest ("Bosque Aleatorio") es más sofisticado. En lugar de dibujar una sola línea separadora, construye **200 árboles de decisión**, cada uno entrenado con datos ligeramente distintos. Cuando hay que predecir, los 200 árboles votan y gana la mayoría.

Es como pedirle opinión a 200 analistas financieros diferentes y tomar la decisión que más se repite. La diversidad de perspectivas hace que el resultado sea mucho más robusto.

¿Por qué es mejor que un solo árbol? Un árbol de decisión solo puede memorizar los datos de entrenamiento (overfitting). Usando 200 árboles con datos distintos, los errores individuales se cancelan entre sí y el modelo generaliza mucho mejor a datos nuevos.

Matriz de Confusión — Random Forest



El Random Forest comete menos errores en ambas direcciones: menos Falsos Positivos (~68 llamadas innecesarias) y menos Falsos Negativos (~49 clientes perdidos) comparado con la Regresión Logística. En términos de negocio: el banco ahorra costos de llamadas innecesarias y pierde menos oportunidades de venta.

~1020 Verdadero Negativo


~155 Falso Positivo

~154 Falso Negativo

~904 Verdadero Positivo

La Matriz de Confusión del Random Forest muestra una clara mejora respecto al modelo anterior. Los errores se reducen en ambas categorías, lo que se traduce directamente en mejor eficiencia para la campaña.

Curva ROC — Random Forest




El Random Forest alcanza un **AUC = 0,911**, notablemente superior al **0,861** de la Regresión Logística. La curva sube muy abruptamente hacia la esquina superior izquierda — el modelo ideal — antes de aplanarse. **Esto significa que con una tasa de falsos positivos del 20% (llamar a 1 de cada 5 clientes que no suscribirían), el modelo ya detecta correctamente al 90% de los suscriptores reales.** Para el banco, este punto de operación representa un balance muy eficiente entre costo y cobertura.

// CAPÍTULO 05

¿Cuál modelo es mejor?

Comparamos ambos modelos usando cuatro métricas estándar, todas calculadas sobre el mismo conjunto de prueba (datos que ninguno de los modelos vio durante el entrenamiento).



¿Qué significa cada métrica?

Accuracy: Porcentaje de predicciones correctas del total. El Random Forest acertó en el 86,2% de los casos. Simple e intuitivo, pero no cuenta toda la historia.

AUC-ROC: Mide qué tan bien separa el modelo a los "sí" de los "no". Va de 0,5 (aleatorio) a 1,0 (perfecto). Un AUC de 0,93 significa que si le mostramos un cliente que suscribió y uno que no, el modelo identifica al correcto el 93% de las veces.

Precision: De todos los que predijo como "sí suscribirá", ¿Qué porcentaje realmente suscribió? Alta precisión = pocas llamadas desperdiciadas.


Recall: De todos los que realmente suscribieron, ¿Qué porcentaje detectó el modelo? Alto recall = pocas oportunidades de venta perdidas.

El gráfico confirma que **el Random Forest (verde) supera a la Regresión Logística (violeta) en las cinco métricas evaluadas**. La diferencia es especialmente notable en **AUC-ROC (0,911 vs. 0,861)** y **Recall (0,857 vs. 0,759)**. El Recall alto del Random Forest es especialmente valioso en este contexto: significa que pierde menos clientes potenciales, minimizando las oportunidades de negocio no capturadas. El eje Y arranca en 0,70 para que las diferencias sean visualmente claras.

Curvas ROC comparadas

La Curva ROC es una de las visualizaciones más usadas en Machine Learning para evaluar modelos de clasificación. Muestra cómo varía la sensibilidad del modelo (qué tan bien detecta los "sí") frente a los falsos positivos que genera, a medida que se ajusta el umbral de decisión.

Comparación de Curvas ROC



La curva verde (Random Forest) está **sistemáticamente por encima** de la violeta (Regresión Logística) en todo su recorrido — no es solo en un punto, sino en cada posible umbral de decisión. El área entre ambas curvas representa la ventaja real del Random Forest. La diferencia de AUC (0,911 vs. 0,861) equivale a pasar de acertar 86 de cada 100 comparaciones "suscriptor vs. no-suscriptor" a acertar 91 de cada 100. Cinco puntos porcentuales que, sobre miles de clientes, representan cientos de suscripciones recuperadas.

Curvas ROC superpuestas. La curva verde (Random Forest) está sistemáticamente por encima de la violeta (Regresión Logística), confirmando que es el mejor modelo para este problema. La línea diagonal punteada representa un clasificador completamente aleatorio — cualquier modelo útil debe estar por encima de ella.

// CAPÍTULO 06

¿Qué aprendimos y qué recomendamos?

Después de explorar el dataset, limpiar los datos, entrenar dos modelos y comparar sus resultados, llegamos a una serie de conclusiones tanto técnicas como de negocio.

Random Forest es el mejor modelo

Con 86,2% de accuracy y AUC de 0,93, supera a la Regresión Logística en todas las métricas. El banco debería usar este modelo para priorizar sus listas de llamadas.

La duración de la llamada lo dice todo

Es la variable más predictiva. El problema es que solo la conocemos después de llamar. Para campañas futuras, hay que apoyarse en las otras variables para decidir a quién llamar.

Apunta a los clientes con historial exitoso

Elegí bien el mes para llamar Un cliente que ya suscribió antes tiene 91,3% de probabilidad de volver a hacerlo. Esta es la lista de oro para cualquier campaña.

Enfócate en jóvenes y jubilados

Los clientes de 18-25 años (70,7%) y mayores de 65 (80,2%) son los segmentos con mayor receptividad. Los de 36-55 son los más difíciles de convencer.

Los clientes sin deudas, mejor candidatos

Clientes sin préstamo hipotecario tienen tasa de suscripción del 57%, frente al 36,6% de los que sí tienen hipoteca. El capital disponible es un factor clave.

! Impacto práctico de usar el modelo:

Si el banco tiene que contactar a 10.000 clientes y usa el Random Forest para priorizar los 5.000 más prometedores, podría esperar obtener aproximadamente un 86% de las suscripciones totales con la mitad del costo operativo. El modelo no es perfecto, pero es significativamente más eficiente que llamar aleatoriamente.

Limitaciones a tener en cuenta

Todo modelo tiene sus limitaciones, y es importante ser honesto al respecto:

- La variable ***duration*** es la más predictiva pero no es accionable antes de la llamada. Un modelo más realista debería evaluarse sin ella para ver el desempeño real.
- Los datos provienen de un banco portugués en un período específico. Las condiciones económicas, culturales y regulatorias pueden variar en otros contextos.
- El modelo captura patrones del pasado. Si el banco cambia su estrategia o el mercado cambia, habría que reentrenarlo con datos más recientes.